프로젝트 최종보고서

팀명: MLS
팀원: 박현빈, 고혜진, 이건아, 조민규

COLORED-MNIST 데이터셋을 이용한 숫자, 전경색, 배경색을 분류하는 모델 설계

(Design of a model for classifying numbers, foreground colors, and background colors using the COLORED-MNIST dataset)

숭실대학교 전자정보공학부 IT 융합전공 고혜진, 박현빈, 이건아, 조민규

최종 발표 녹화 영상: https://youtu.be/pPXmcnDv0kk

ABSTRACT

MNIST 데이터셋은 흑백 이미지로 구성되어 현실 데이터를 충분히 반영하지 못하는 한계가 있음. 본 연구는 숫자, 전경색, 배경색 정보를 포함한 Colored-MNIST 와 손글씨 데이터를 활용하여 다중 레이블 분류 모델을 설계하고 성능을 평가하였음. 모델 비교 결과, LightGBM 은 숫자, 전경색, 배경색 분류에서 각각 94.47%, 99.84%, 100%의 정확도로 가장 우수한 성능을 보였음. 또한, 20% 회전율과 노이즈 추가는 모델의 일반화 성능을 강화한 반면, 밝기 조정과 대칭 변환은 성능 저하를 초래함. 본 연구는 Colored-MNIST 와 손글씨 데이터를 활용한 다중 레이블 분류의 가능성을 입증하였으며, 데이터 확장과 증강 기법 개선을 통해 성능을 더욱 향상시킬 수 있음을 시사함.

I. 서론

기존 MNIST 데이터셋은 숫자 분류 문제를 해결하기 위한 벤치마크로 널리 사용되어 왔지만, 흑백 이미지로 구성되어 있어 다양한 데이터 특성을 반영하는 데 한계가 존재한다. 현실 세계의 데이터는 다차원적이고 다양한 특징을 포함하고 있어 보다 복잡한 문제를 다룰 수 있는 데이터셋의 필요성이 대두되고 있다.
Colored-MNIST 는 기존 MNIST 데이터셋을 확장하여 숫자 분류와 함께 전경색(Foreground Color) 및 배경색(Background Color)의 RGB 값을 추가한 다중 레이블 분류 문제를 제공한다. 이 데이터셋은 숫자의 형태, 색상 정보 등 여러 특징을 포함하며, 다중 레이블 분류와 같은 보다 현실적인 문제를 해결하는 데 적합하다.
본 프로젝트의 목적은 Colored-MNIST 데이터셋을 활용하여 다중 레이블 분류 문제를 해결하기 위한 머신러닝 모델을 설계하고, 다양한 데이터 증강 기법을 적용하여 모델의 일반화 성능을 향상시키는 것이다. 이를 통해, 다양한 머신러닝 알고리즘의 성능을 비교 분석하고, 최적의 데이터 증강 기법을 제안하고자 한다.

II. 본론

1. 데이터 전처리 및 데이터 구성

본 연구에 사용된 데이터는 Colored-MNIST 데이터셋으로 다음과 같이 구성되었다.

1.1 숫자 이미지 생성

MNIST 데이터셋의 기본 구조를 유지하면서 제공된 다양한 폰트를 사용해 흑백 숫자 이미지를 생성하였다. 이를 통해 모델이 다양한 스타일의 숫자에 대해 일반화된 학습을 수행할 수 있도록 하였다.
각 숫자(0~9)는 랜덤하게 선택된 폰트로 렌더링되었으며, 흑백 이미지로 변환되었다. 생성된 데이터는 28 x 28 크기의 배열 형태로 저장되었다.

1.2 컬러 데이터 생성

전경색(foreground color)과 배경색(background color)을 랜덤하게 지정하여 컬러 데이터를 생성하였다. 전경색과 배경색이 동일하지 않도록 조건을 설정함으로써, 색상 구분 학습이 가능하도록 하였다.
무지개 색상(빨강, 주황, 노랑, 초록, 파랑, 남색, 보라)의 RGB 값을 사용하여 각 숫자 이미지에 전경색과 배경색을 적용하였으며, 숫자의 픽셀 값은 전경색으로, 배경은 배경색으로 처리하여 총 데이터셋 120,000 개를 생성하였다.

1.3 데이터셋 분할

생성된 데이터는 효율적인 학습과 평가를 위해 훈련, 검증, 테스트 데이터셋을 분할하였다.
훈련 데이터는 데이터의 70%를 할당하여 모델 학습에 사용하였고, 검증 데이터는 데이터의 15%를 할당하여 하이퍼파라미터 튜닝 및 성능 검증에 사용하였으며, 테스트 데이터는 데이터의 15%를 할당하여 최종 성능 평가에 사용하였다.
각 데이터셋은 클래스의 균형을 유지하며 분할되었으며, 전경색과 배경색의 다양한 조합이 포함되도록 설계되었다.

2. 데이터 증강

모델의 일반화 성능을 향상 시키기 위하여 데이터 증강 기법을 적용하였다. 증강 데이터의 비율은 훈련 데이터의 약 20%에 대해 증강을 수행하였다.

2.1 노이즈 추가

이미지 픽셀 값에 정규분포를 따르는 랜덤 노이즈를 추가하여, 모델이 잡음에 강건한 특성을 가지도록 하였다. 노이즈의 세기는 noise_level = 0.1 로 설정하였으며, 추가 실험에서 0.05 및 0.2 값으로도 실험하였다.

2.2 회전 변형

이미지를 무작위로 회전시키는 변형을 통해 다양한 각도에서 숫자를 인식하는 학습을 유도하였다. 최대 회전 각도는 ±20° 로 설정하였다.

3. 모델 구성

Colored-MNIST 데이터셋은 숫자 뿐만 아니라 전경색, 배경색 정보를 포함하는 특수한 데이터셋으로 분류 성능을 평가하기 위해 다양한 머신러닝 모델을 사용하였다.

3.1 Random Forest

Random Forest 는 여러 개의 결정 트리를 앙상블로 묶어 학습과 예측을 수행하는 모델이다. 데이터 샘플링과 특성 샘플링을 통해 과적합을 방지하고, 강력한 예측 성능을 제공한다. Colored-MNIST 분류를 진행할 때 데이터에 전재하는 다양한 전경색 및 배경색 조합에 대한 복잡한 관계를 학습 가능하며, 과적합 방지에 강하고 숫자와 색상 정보 모두에서 높은 분류 성능을 보인다.

3.2 KNN

KNN 은 새로운 데이터가 주어졌을 때, 가장 가까운 k 개의 이웃 데이터를 기반으로 예측을 수행하는 모델이다. 유클리디안 거리 등 데이터 간의 거리를 계산하여 가장 가까운 이웃 데이터를 찾고 다수결 방식으로 클래스 라벨을 결정한다. 전경색과 배경색 간의 명확한 구분이 가능한 데이터 구조에서 좋은 성능을 보인다.

3.3 SVM

SVM 은 데이터를 초평면으로 분리하여 분류를 수행하는 모델이다. 선형적으로 분리되지 않는 데이터를 처리하기 위해 커널 트릭을 사용한다. Colored-MNIST 분류에서 전경색과 배경색 간의 미묘한 차이를 고차원 공간으로 매핑하여 효과적으로 분리할 수 있다.

3.4 Logistic Regression

로지스틱 회귀는 선형 모델로, 입력 변수와 클래스 간의 관계를 확률로 모델링한다. 각 특성에 대한 가중치를 학습하여 출력값을 0 과 1 사이의 확률로 변환하고, 이를 기반으로 분류를 수행한다. Colored-MNIST 분류에서 로지스틱 회귀는 간단한 모델로 빠르게 학습할 수 있지만, 복잡한 색상 조합이나 고차원 데이터에서 성능이 제한적일 수 있다.

3.5 LightGBM

LightGBM 은 대규모 데이터셋과 고차원 데이터에 적합한 Gradient Boosting Decision Tree 기반의 프레임워크로 여러 개의 약한 예측 모델을 순차적으로 학습하여 강한 예측 모델을 만드는 앙상블 학습 기법이다. 데이터의 Histogram 기반 학습 방식을 사용하여 학습

속도가 빠르며, 다중 클래스 분류, 대규모 데이터 처리 능력 등의 장점이 있다.
본 프로젝트에서는 Random Forest, KNN, SVM, Logistic Regression 과의 성능 비교를 수행하였을 때 LightGBM 이 가장 뛰어난 성능을 보이게 되어 모델로 선정하였다.

4. 성능 평가 기법

Colored-MNIST 데이터셋의 성능은 다양한 평가 지표를 기반으로 측정되며, 각 모델의 분류 정확도 및 성능을 다각적으로 분석할 수 있다. 본 연구에서는 Accuracy, Precision, Recall, F1-Score 와 같은 주요 평가 지표를 사용하여 모델 성능을 분석하였다. 또한, 혼동 행렬(Confusion Matrix)을 통해 각 클래스별 분류 성능을 시각화하였다.

4.1 Accuracy

Accuracy 는 모델이 전체 데이터 중에서 올바르게 분류한 비율을 나타낸다. 모든 클래스에서 모델의 전반적인 분류 성능을 평가하는 데 사용된다.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

macro avg 는 각 클래스별 정확도의 평균을 의미하며, 클래스 불균형을 고려하지 않은 지표로, 모델이 전체 클래스에서 균등하게 성능을 발휘하는지 확인하는 데 유용하다. weighted avg 는 각 클래스의 샘플 수를 고려한 평균으로, 데이터셋 내의 클래스 분포가 불균형할 때 중요한 평가 지표이다. 이 결과를 통해 모델이 데이터셋의 균형을 잘 맞추고 있다는 것을 알 수 있다.

4.2 Precision

Precision 은 모델이 특정 클래스로 예측한 샘플 중에서 실제로 해당 클래스에 속하는 샘플의 비율을 측정한다. 잘못된 긍정 예측(False Positives)을 최소화하는 데 초점을 둔다.

$$Precision = \frac{TP}{TP + FP}$$

4.3 Recall

Recall 은 특정 클래스에 속하는 모든 샘플 중에서 모델이 올바르게 예측한 비율을 나타낸다. 놓치는 샘플(False Negatives)을 줄이는 데 중점을 둔다.

$$Recall = \frac{TP}{TP + FN}$$

4.4 F1-Score

F1-Score 는 Precision 과 Recall 의 조화 평균으로, 두 지표 간의 균형을 평가한다. Precision 과 Recall 간의 트레이드오프를 측정할 때 적합하다.

$$F1 - Score = 2 \times \frac{Precision + Recall}{Precision + Recall}$$

4.5 Confusion Matrix

혼동 행렬은 각 클래스에 대한 예측 결과를 시각적으로 보여준다. 특정 클래스에서의 모델의 오류 유형(False Positives, False Negatives)을 파악하는 데 유용하다.

III. 실험

본 실험은 Colored-MNIST 데이터셋을 활용하여 숫자, 전경색, 배경색 분류 성능을 극대화하는 방향으로 진행되었다. 데이터 증강 기법과 모델 최적화 전략을 적용하여 모델의 일반화 성능을 높이는 데 중점을 두었으며,

실험 결과를 통해 최적의 모델 설정을 도출하였다.

1. 데이터 증강

1.1 노이즈 추가

Colored-MNIST 데이터셋에 정규분포를 따르는 랜덤 노이즈를 추가하여 모델의 견고성을 강화하였다.

노이즈 추가	숫자 분류	전경 분류	배경 분류
5%	0.9173	0.9981	0.9981
10%	0.9447	0.9984	1.0000
20%	0.8292	0.9909	1.0000

Table 1. 노이즈 추가 비율에 따른 정확도 지표.

noise_level 값으로 0.05, 0.1, 0.2 를 실험한 결과 0.05 는 노이즈 강도가 약하여 0.1 보다 모델의 일반화 성능 향상에서 떨어지는 모습을 보였으며, 0.2 는 노이즈가 너무 강하여 숫자 분류에서 성능이 많이 저하되어 0.1 에서 가장 적절한 성능을 보이는 것을 확인하였다.

1.2 회전 변형

본 실험에서는 데이터 증강 기법의 일환으로 회전 변형을 적용하여 모델의 성능 변화를 분석하였다. 이를 위해 다양한 화전율을 실험하였으며 각 회전율에 따른 숫자, 전경색, 배경색 분류 정확도를 측정하였다.

회전율	숫자 분류	전경 분류	배경 분류
10%	0.9839	0.9994	1.0000
20%	0.9447	0.9984	1.0000
30%	0.8957	0.9969	1.0000
40%	0.8514	0.9962	1.0000
60%	0.7720	0.9934	0.9999

Table 2. 회전율 비율에 따른 정확도 지표

실험 결과 20% 회전율이 데이터 다양성과 모델 성능의 균형을 최적화하는데 가장 적합한 범위로 판단하였다. 10%는 과대적합이 일어나고, 30%이상은 과도한 회전으로 이미지 정보 손실이 발생함에 따라 최대 20%범위에서 랜덤으로 이미지에 회전을 추가하였다.

1.3 감도, 명도, 밝기 변환

본 실험에서는 데이터 증강 기법으로 감도, 명도, 밝기 변환을 적용하여 모델의 성능 변화를 평가하였다. 감도, 명도, 밝기 변환은 이미지의 색상과 밝기 조정을 통해 다양한 환경에서의 모델 성능을 높이고, 데이터의 다양성을 증가시키는 역할을 한다.

증강 기법	숫자 분류	전경 분류	배경 분류
기존 데이터	0.9447	0.9984	1.0000
증강 기법 적용	0.7845	0.9970	0.9990

Table 3. 감도, 명도, 밝기 변환을 적용한 증강 기법과 기존 데이터의 정확도 지표

감도, 명도, 밝기 변환을 동시에 적용한 후 기존 데이터와의 정확도를 비교해 보니 숫자 분류에 대한 정확도가 크게 감소하게 되었고, 전경색, 배경색 분류에서도 약간의 정확도 감소를 확인하였다. 결과적으로, 감도, 명도, 밝기 변환을 통해 모델이 전반적인 색상 및 밝기 변화에 대한 적응력을 향상시키면서, 데이터의 단순성을 낮출 수 있었다.

1.4 대칭 변환

본 실험에서는 데이터 증강 기법의 일환으로 대칭 변환(이미지 좌우반전)을 적용하여 모델 성능 변화를 분석하였다. 이를 통해 대칭 변환이 숫자, 전경색, 배경색 분류 성능에 미치는 영향을 평가하고, 데이터 증강 기법으로 활용 가능성을 검토하였다.

대칭 유무	숫자 분류	전경 분류	배경 분류
대칭 적용	0.6834	0.9959	0.9961
대칭 미적용	0.7845	0.9970	0.9990

Table 4. 대칭 적용 유무에 따른 정확도 지표

대칭 변환은 데이터 다양성을 증가시키고 모델의 일반화 성능을 향상시킬 것으로 기대되었으나, 실험 결과 숫자 분류 성능에서 부정적인 영향을 미치는 것으로 확인되었다. 특히, 일부 숫자(예: 6 과 9, 2 와 5 등)의 대칭 구조가 원래의 숫자 특성을 왜곡하여 모델 혼동을 유발하였다. 반면, 전경색과 배경색 분류는 대칭 변환 여부에 관계없이 유사한 정확도를 보여, 대칭 변환이 색상 분류에는 거의 영향을 미치지 않음을 확인하였다.

결론적으로, 대칭 변환은 숫자 분류 모델의 성능 저하를 유발할 가능성이 높아 본 연구에서는 데이터 증강 기법으로 대칭변환을 적용하지 않기로 결정하였다.

1.5 증강 비율 설정

증강 데이터	숫자 분류	전경 분류	배경 분류
10%	0.8875	0.9970	1.0000
20%	0.9447	0.9984	1.0000
30%	0.9667	0.9995	1.0000
40%	0.9742	0.9998	1.0000

Table 5. 증강 비율에 따른 정확도 지표.

실험 결과 훈련 데이터에서 증강 비율을 높일수록 성능이 좋아지는 것을 확인하였다. 본 프로젝트의 목적은 실제와 유사한 환경에서 분류를 목적으로 하여 훈련 데이터셋에 많은 노이즈를 추가하는 것이 아닌 실제값과 유사하다고 판단되는 20%로 증강 비율을 설정하였다.

2. 모델 선정

Colored-MNIST 데이터셋의 특성과 분류 문제의 요구사항을 반영하여, 본 프로젝트에서는 LightGBM, Random Forest, KNN, SVM, Logistic Regression 모델을 선정하여 성능을 비교하였다.

모델	숫자 분류	전경 분류	배경 분류
LightGBM	0.9447	0.9984	1.0000
Random Forest	0.8917	0.9853	1.0000
KNN	0.8727	0.8692	1.0000
SVM	0.5053	0.9293	1.0000
Logistic Regression	0.2491	0.8839	0.9997

Table 6. 모델에 따른 정확도 지표

모델 성능 비교 결과, LightGBM 이 숫자, 전경색, 배경색 분류에서 가장 뛰어난 성능을 보여 Colored-MNIST 데이터셋에 가장 적합한 모델로 선정되었다. Random Forest 는 안정적이고 빠른 학습 속도를 보였으며, KNN 은 단순한 구현으로 전경색과 배경색 분류에서 양호한 성능을 보였다. 반면, SVM 과 Logistic Regression 은 숫자 분류에서 성능이 낮아 적합하지 않은 것으로 나타났다.

3. 성능 평가

3.1. Precision, Recall, F1-score

본 연구에서는 모델의 전반적인 분류 능력 뿐만 아니라 각 클래스 별로 모델이 얼마나 잘 예측하는지를 면밀히 살펴보았다. 이를 위한 성능 평가 지표로 Precision, Recall, F1-score 를 함께 고려하였다.

	precision	recall	F1-score	support
0	0.83	0.69	0.75	943
1	0.88	0.85	0.86	847
2	0.68	0.75	0.71	910
3	0.64	0.77	0.70	877
4	0.86	0.77	0.81	960
5	0.77	0.82	0.80	890
6	0.69	0.73	0.71	856
7	0.76	0.73	0.74	923
8	0.79	0.68	0.73	962
9	0.69	0.76	0.72	892

Table 7. Precision, Recall, F1-score 성능 평가

전체적으로 모델은 숫자 1 에서 가장 뛰어난 성능을 보였으며, F1-Score 는 0.86 으로

우수했다. 숫자 0, 2, 3, 6 에서는 상대적으로 낮은 Precision 과 Recall 값을 기록했지만, 전반적으로 양호한 성능을 유지했다. 특히 숫자 4, 5, 7 에서는 높은 F1-Score(0.81, 0.80, 0.74)를 보이며, 모델의 균형 잡힌 예측 성능을 나타냈다. 이는 모델이 해당 숫자들에 대한 분에서 비교적 높은 정확도를 달성했음을 의미하며, 다양한 범위의 데이터에 대해서도 잘 일반화된 성능을 보였다고 할 수 있다.

3.2. Accuracy

본 실험에서는 모델의 전반적인 성능을 평가하기 위해 Accuracy 지표를 사용하였다.

Accuracy	0.75		
Macro avg	0.76	0.75	0.75
Weighted avg	0.76	0.75	0.75

종합적으로, 모델은 전체적으로 안정적인 성능을 보여주었으며, 높은 정확도와 균형 잡힌 평가 결과를 바탕으로 실제 데이터에 대해 좋은 예측력을 가지고 있음을 확인할 수 있었다.

IV. 추가 실험

1. 손 글씨 데이터 적용

본 실험에서는 기존 Colored-MNIST 데이터셋에 손 글씨 데이터셋을 추가하여 LightGBM 모델의 성능을 평가하였다.

1.1 데이터셋 구성

기존 Colored-MNIST 데이터셋으로 총 120,000 개 데이터를 학습에 사용하였으나, 손 글씨 데이터셋을 추가하기 위해 기존 데이터셋을 60,000 개로 축소하고 총 400 개의 손 글씨 데이터를 추가하여 최종 데이터셋을 60,400 개로 구성하였다.

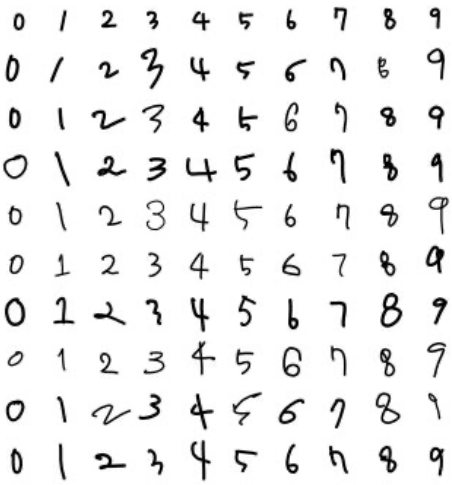


Fig 1. 손 글씨 이미지

손 글씨 데이터셋은 8 장의 이미지로부터 400 개의 데이터를 추출하고, 각 이미지에 전경색과 배경색을 추가하여 컬러 데이터를 생성하였다.



Fig2. 손 글씨 데이터셋을 추가한 컬러 데이터 생성

1.2 실험 결과 분석

데이터셋 비교	숫자 분류	전경 분류	배경 분류
기존 데이터셋	0.7599	0.9950	0.9999
손 글씨 추가	0.7534	0.9926	0.9997

Table7. 기존 데이터셋과 손 글씨 데이터를 추가한 데이터셋의 정확도 지표

기존의 데이터셋을 60,400 개로 제한하여 LightGBM 모델을 돌려본 결과와 손 글씨 데이터셋을 추가한 결과를 비교해 보았을 때 손 글씨 데이터는 다양한 필체와 불균일한 스타일을 포함하고 있어 모델 학습에 어려움이 있고, 400 개의 손 글씨 데이터셋은 적은

양이기에 모델이 충분한 학습을 수행하지 못하여 숫자 분류 성능이 일부 저하되었다. 향후 손 글씨 데이터셋을 확장하여 더 많이 학습하게 된다면 숫자 분류에 대한 정확도가 올라갈 것으로 기대된다.

V. 결론

본 연구는 Colored-MNIST 데이터셋을 활용하여 숫자, 전경색, 배경색을 다중 레이블로 분류하는 머신러닝 모델을 설계하고 최적화하는 과정을 다루었음. 연구 결과 LightGBM 모델이 가장 높은 성능을 보여 Colored-MNIST 데이터셋에 가장 적합한 모델로 선정되었음. 특히, 데이터 증강 기법을 활용한 노이즈 추가와 회전 변형은 모델의 일반화 성능을 크게 향상시키는 데 기여하였으며, 다양한 데이터 조합에 대해 우수한 분류 성능을 보였음.

추가 실험으로 손글씨 데이터셋을 Colored-MNIST 에 결합하여 모델의 확장 가능성을 평가함. 손글씨 데이터의 도입은 다양한 필체와 스타일에 대한 모델의 대응력을 강화하는 가능성을 열어주었으나, 데이터의 양적 부족으로 인해 일부 성능 저하가 발생. 이를 해결하기 위해, 향후 더 많은 손글씨 데이터를 수집하고, 추가적인 증강 기법을 적용하여 데이터의 다양성을 높일 계획.

본 연구는 현실 세계에서의 복잡한 데이터를 다루기 위한 모델 설계와 최적화의 중요성을 강조하며, 향후 더 다양한 데이터셋과 환경에서의 활용 가능성을 제시함. 이를 통해 머신러닝 모델이 실제 문제 해결에 더욱 효과적으로 기여할 수 있기를 기대함.

Reference

[1] https://www.ibm.com/kr-ko/topics/data-augmentation : 데이터증강의 이해

[2] https://lightgbm.readthedocs.io/en/latest/index.html : LightGBM 의 이해

[3] https://velog.io/@kkiyou/lgbm#22-overfitting%EA%B3%BC%EC%A0%81%ED%95%A9-%EC%A1%B0%EC%A0%95-parameters : LightGBM 의 이해